Grupo – AL030
Gonçalo Ribeiro 82303
André Mendonça 82304

Parte 1 – Métodos de Classificação

1.1 Escolha das *features*

Com o objetivo de se obter um erro dentro dos limites de tolerância (≤ 30%), tendo em conta os exemplos de classificação (*True* ou *False*) de palavras dados no enunciado do projeto e as palavras para avaliação incluídas no ficheiro de texto, optou por se escolher as seguintes *features*:

→ Tamanho da palavra;
→ Paridade do número de vogais;
→ Primeira letra da palavra ser uma vogal;
→ Palavra tem acentuação;
→ Palavra tem letras repetidas;

1.2 Análise dos métodos de aprendizagem

Com estas *features* foram testados diferentes métodos de aprendizagem através dos seguintes algoritmos, de onde se obtiveram as seguintes percentagens de sucesso de classificação:

Algoritmo	Teste 1	Teste 2
Neighbors	74%	72%
Decision Tree	84%	84%
Linear	73%	79%

Antes de uma decisão final, foi repetida a análise dos métodos de aprendizagem com as seguintes *features*:

→ Número ímpar de letras;
→ Começar e terminal em vogal;
→ O sufixo da palavra ser uma palavra de 3 letras já classificada;

1.3 Conclusão

Após a revisão dos resultados obtidos, verificou-se que nenhuma destas últimas *features* alcançava uma percentagem maior do que as que já tinham sido obtidas anteriormente, continuando assim o ***Decision Tree*** a ter a maior percentagem de sucesso.

Apesar da utilização dos parâmetros ***max_depth*** (profundidade máxima da árvore de decisão) e ***min_samples_split***, as percentagens de sucesso nunca foram superiores relativamente às anteriores.

$$y = sign(\theta^T f(x))$$

Figura 1

Em suma, a partir da função acima apresentada e substituindo f(x) pelo vetor de *features* citado anteriormente e tendo em conta y (variável de saída) e as percentagens obtidas e utilizando as *features* definidas para classificar as palavras, conclui-se que o melhor método de aprendizagem é o ***Decision Tree***.

Parte 2 – Métodos de Regressão

1.1 Análise dos métodos de aprendizagem

$$y = g(x)$$

Figura 2

Para o estudo do método de regressão utilizando a função da figura 2, foram implementados vários tipos de métodos de regressão (*Linear*, *Tree* e *Kernel Ridge*), sendo que a avaliação comparativa foi realizada entre os métodos ***Tree*** e ***Kernel Ridge***, pois os métodos de regressão *Linear* e *Tree* têm ambos o mesmo resultado de output (y=FAILED da figura 2), comparação esta que foi maioritariamente realizada observando os gráficos obtidos através da implementação dos algoritmos:

Tree Regression:

O método de regressão *Tree Regression* tem a tendência a ficar *overfitted* (criação de árvores de decisão demasiado complexas não generalizando assim a informação dada como input) em relação aos dados existentes.

Na tentativa de que isso não acontecesse, foi necessário ajustar o parâmetro "***Max_depth***" consoante o número exemplos a serem testados (parâmetro "***min_sample_split***"), sem sucesso, neste caso podemos observar nos gráficos 1 e 2 que o teste tem como output "*FAILED*" não confirmando assim a validação cruzada.

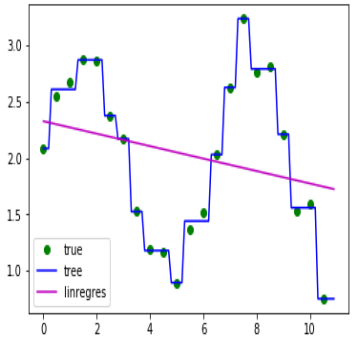

Gráfico 1: Teste de Regressão 1 - FAILED

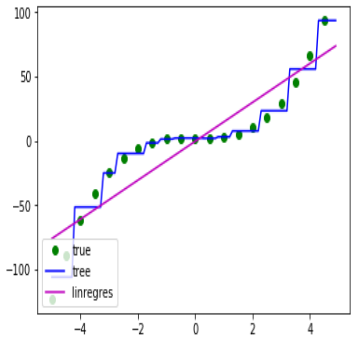

Gráfico 2: Teste de Regressão 2 - FAILED

Kernel Ridge:

Tipicamente o método de regressão ***Kernel Ridge*** é utilizado para conjuntos de informação de tamanho médio, utilizando "*squared error loss*" (função de perda), tendo assim uma execução consideravelmente rápida.

Neste caso ajustando os parâmetros de validação cruzada (parâmetro "***cv***") e da própria função de *Kernel Ridge* (parâmetro "***kernel***", "***alfa***" e "***gama***").

Para o caso em que **kernel=*'rbf'*** (*Radial Basis Function*) a variância de valores é testada no parâmetro "***gama***" da função ***Kernel Ridge***, sendo que apenas o primeiro teste de regressão confirmou a validação cruzada.

Grupo – AL030
Gonçalo Ribeiro 82303
André Mendonça 82304

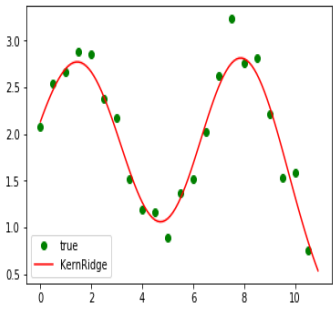

Teste de Regressão 1 (kernel = rbf) - OK

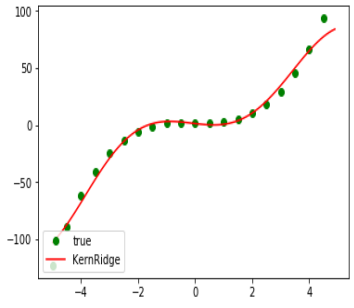

Teste de Regressão 2 (kernel = rbf) - FAILED

Para o caso em que **kernel='linear'** a variância de valores é testada no parâmetro "***alpha***" da função ***Kernel Ridge***, sendo que apenas o segundo teste de regressão confirmou a validação cruzada.

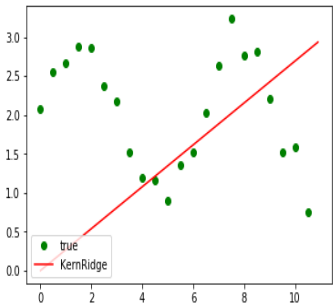

Teste de Regressão 1 (kernel = linear) - FAILED

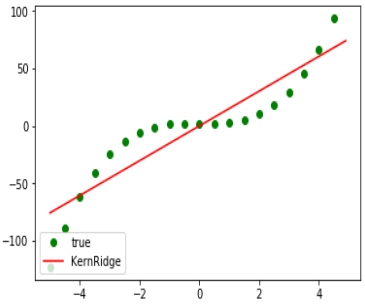

Teste de Regressão 2 (kernel = linear) - OK

GridSearchCV with Kernel Ridge:

Com o intuito de obter validação em ambos os casos de teste, através de uma exploração complementar, foi executado o método de aprendizagem ***GridSearchCV*** baseado no método *Kernel Ridge*, método este que executa uma procura exaustiva:

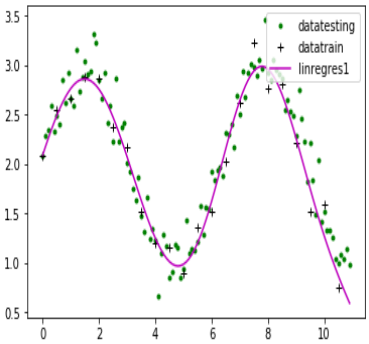

Teste de Regressão 1 (kernel = rbf) - OK

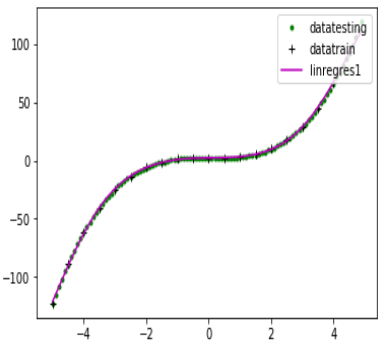

Teste de Regressão 2 (kernel = rbf) - OK

Parte 3 – Aprendizagem por Esforço

Qual é a politica a seguir em cada estado?

A politica a seguir em cada estado é dada pela função **Q2pol(Q,eta=5)** em que **Q** é um valor da composição estado-ação neste mundo e eta é a variável relativa à exploração (quanto menor for o valor de **eta**, maior será a capacidade de exploração).

Sendo assim a politica é dada pela expressão: **np.exp(eta*Q)/np.dot(np.exp(eta*Q),np.array([[1,1],[1,1]])).**

Seguindo a politica apreendida para onde é que o agente vai se começar no estado 3?

Realizando alguma pesquisa sobre as matrizes dadas como output e tendo em conta a expressão que referencia a politica apreendida anteriormente, é possível concluir que o agente se desloca para o estado 4 com a ação 0 (começando no estado 3).

Representação gráfica do ambiente no qual o ambiente se move

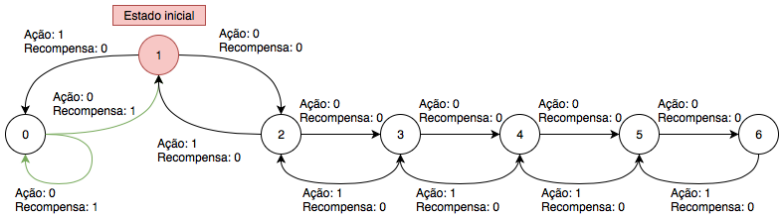

Grafo de estados

Qual é a função de recompensa?

$$R(s,a,s') = \begin{matrix} 1, se\ s=0\ e\ (s'=0\ ou\ s'=1) \\ 0, para\ qualquer\ outro\ caso \end{matrix}$$

Como é que o agente se move?

É possível observar através do grafo apresentado anteriormente a forma como o agente se move neste mundo:

- O agente passa para o estado seguinte se a ação a executar for a ação 0, por outro lado o agente retorna para um estado anterior se a ação a executar for a ação 1.
- No caso de o estado atual ser o estado 0, a ação 1 faz com que o agente permaneça no mesmo estado com uma recompensa de 1.
- Também consegue obter uma recompensa de 1 se passar do estado 0 para o estado 1.